

SAN


Side Adapter Network for Open-Vocabulary Semantic Segmentation

收录于：CVPR23

摘要：


- 提出Side Adapter Network(SAN), 一个使用预训练视觉-语言模型来完成开放词汇语义分割任务的架构
- 将语义分割任务建模为一个**区域识别**任务
- side network在一个**冻结的CLIP模型**后面连接两个分支：
 - 一个用于预测**掩码proposals**
 - 另一个用于预测CLIP模型识别类掩码的**注意力偏移**
- 网络进行**端到端训练**
 - 使得侧网适应冻结的CLIP模型, 因此预测的到的proposals具有CLIP的感知能力(CLIP-aware)
- 本方法比其他方法训练参数减少了18倍, 推理速度更快提高了19倍

结构



- 红色虚线是训练过程中的梯度流,
- SAN两个分支: mask proposals, attention bias。这样的解耦设计提高了分割性能, 因为CLIP用于识别mask的区域和mask区域本身
- 将浅层CLIP块的特征融合到SAN中, 更深的块与attention bias结合


- SAN的结构




- 与ViT相似，都是将图像分成patch然后线性投影成visual token。与N个可学习的query token连起来后输入Transformer
- 输出：mask proposals与相应的attention biases，attention bias用于掩膜识别
- 在生成mask时

- 公式：
$$\mathbf{M} = \mathbf{V}_{\text{mask}} \mathbf{Q}_{\text{mask}}^T \quad M = V_{\text{mask}} Q_{\text{mask}}^T$$

- $Q_{\text{mask}} \in \mathbb{R}^{N \times 256}$ 为**query tokens**经过三层MLP(多层感知机)得到， $v_{\text{mask}} \in \mathbb{R}^{\frac{H}{16} \times \frac{W}{16} \times N}$ 为**visual tokens**经过三层MLP得到，H和W是输入图像的高和宽，得到的 $M \in \mathbb{R}^{\frac{H}{16} \times \frac{W}{16} \times N}$
- 在生成attention bias时
 - 公式： $B = V_{\text{attn}} Q_{\text{attn}}^T$
 - $Q_{\text{attn}} \in \mathbb{R}^{N \times 256}$ 也为**query tokens**经过三层MLP得到， $V_{\text{attn}} \in \mathbb{R}^{\frac{H}{16} \times \frac{W}{16} \times K \times 256}$ 为**visual tokens**经过三层MLP得到，K是ViT CLIP模型的注意力头个数，得到的 $B \in \mathbb{R}^{\frac{H}{16} \times \frac{W}{16} \times K \times 256}$
 - 实际上 Q_{mask} 和 Q_{attn} 可以共享
 - **attention bias用于CLIP的多个自注意力层** [问题1](#)
- visual token的特征融合：
 - ViT由visual token和【CLS】token组成，但SAN只融合了visual token
 - ---融合特征的具体操作
 - 将CLIP的{stem, 3, 6, 9}层与SAN的{stem, 1, 2, 3}层融合
- 结合attention bias进行mask recognition：
 - 示意图：



- CLIP只能通过【CLS】token来进行图像级识别，该工作的思路是通过【CLS】token在感兴趣区域的attention map来指导准确的mask识别。
- 创建一组【SLS】tokens，被视觉token单向更新，不影响视觉token和【CLS】token。
- SLS更新公式：
$$\mathbf{X}_{[SLS]}^{l+1} = \text{softmax}(\mathbf{Q}_{[SLS]}^l \mathbf{K}_{\text{visual}}^l + \mathbf{B}_k) \mathbf{V}_{[SLS]}^l$$
 - $B_k \in R^{\frac{H}{16} \times \frac{W}{16} \times N}$ 为第L层第k个头的注意力偏移attention bias
 - $Q_{[SLS]} = W_q X_{[SLS]}$,
 - $V_{[SLS]} = W_v X_{[SLS]}$,
 - $K_{[visual]} = W_k X_{[visual]}$
 - 来自代码： $X \in R^{K \times N \times C}$
- 因为加入了注意力偏移 B_k ，SLS的特征逐渐演变为适合mask预测。【Prompt?】



- 注意力与Masks来自同一个Query token，所以有着对应关系

- 通过比较【SLS】token【尺寸为1xN】和CLIP文本embedding【尺寸为1xC】之间的距离/相似性，获得mask的类预测，计为 $P \in \mathbb{R}^{C \times N}$ ，C是类别数。
- 利用M和P可以计算出分割图 $S = M \times P^T$ 。 $S \in \mathbb{R}^{\frac{H}{16} \times \frac{W}{16} \times C}$ ，即语义分割的标准输出
- 损失函数：
 - mask生成：dice loss L_{mask_dice} 和二元交叉熵损失BCE L_{mask_bce}
 - mask识别：交叉熵损失 L_{cls}
 - 总损失：

$$L_{seg} = \lambda_1 L_{mask_dice} + \lambda_2 L_{mask_bce} + \lambda_3 L_{cls}$$

, $\lambda_1, \lambda_2, \lambda_3$ 分别为为5.0,5.0,2.0